



## BatchNorm и LayerNorm

Дима Авдеев (ВШЭ), Игнат Чернышов (МФТИ), Влад Кузнецов (ментор)

AI360, Москва



### Постановка проблемы

- Хотим обучить глубокую нейронную сеть.
- Для глубоких нейронных сетей изменение одного слоя может сильно изменить следующий.
- Возникает проблема долгого обучения, тщательного подбора гиперпараметров.
- Для ускорения обучения используется разбиение train выборки на батчи.
- Возникает идея посмотреть на матожидание и отклонение данных.

### Идеи BatchNorm и LayerNorm

- Статьи [1, 2] предлагают нормализацию данных после каждого слоя, предлагают менять среднее отклонение (отвечает за дисперсию) и среднее (отвечает за матожидание) данных.
- Batch предлагает брать квадратное среднее отклонение и среднее по батчу, Layer — по слою.
- Для каждого параметра/координаты  $x_i$  считаем  $\hat{x}_i$ , которое считается по батчу  $\mathcal{B}$  через среднее батча  $\mu_{\mathcal{B}}$  и среднее квадратное отклонение  $\sigma_{\mathcal{B}}^2$ :

$$\mu_{\mathcal{B}} = \frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} x_i$$

$$\sigma_{\mathcal{B}}^2 = \frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} (x_i - \mu_{\mathcal{B}})^2$$

$$\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}}$$

- $\epsilon$  выбирается любым маленьким, он нужен лишь для избежания деления на 0.
- Далее для каждого перцептрана обучаются следующие параметры.

$$y_i = \gamma \hat{x}_i + \beta$$

- После окончания обучения параметры «замораживаются», после чего делают дополнительные вычисления для избежания смещённой оценки. Мы опускаем обозначение индекса нейрона ( $k$ ).

$$E[x] \leftarrow E_{\mathcal{B}}[\mu_{\mathcal{B}}], \text{Var}[x] \leftarrow \frac{m}{m-1} E_{\mathcal{B}}[\sigma_{\mathcal{B}}^2]$$

$$y = \frac{\gamma}{\sqrt{\text{Var}[x] + \epsilon}} \cdot x + (\beta - \frac{\gamma \cdot E[x]}{\sqrt{\text{Var}[x] + \epsilon}})$$

- Доказываются некоторые полезные свойства нормализации, например при умножении на скаляр сохраняются свойства матрицы Якоби.

$$\text{BN}(Wu + b) = \text{BN}(Wu) = \text{BN}((\alpha W)u)$$

$$\frac{\partial \text{BN}((\alpha W)u)}{\partial u} = \frac{\partial \text{BN}(Wu)}{\partial u}$$

$$\frac{\partial \text{BN}((\alpha W)u)}{\partial (\alpha W)} = \frac{1}{\alpha} \cdot \frac{\partial \text{BN}(Wu)}{\partial W}$$

### Эксперименты

В оригинальной статье [1] проводились эксперименты с Batch нормализацией и без неё по обучению многослойного полносвязного перцептрана на MNIST (определение числа по картинке  $28 \times 28$  пикселей) со следующими параметрами:

- 3 полносвязных скрытых слоя по 100 нейронов каждый.
- Функция активации: сигмоида. Используется стандартный градиентный спуск для обучения.

Мы повторили данный эксперимент, кроме того, была добавлена Layer нормализация для того чтобы сравнить методы из статей [1, 2]. В таблице ниже приведены вычисления accuracy после каждого 5000 шагов.

Таблица 1: Сравнение итоговой точности на разных шагах во времени обучения MNIST

Model	Acc1, %	Acc2, %	Acc3, %	Acc4, %	Acc5, %	Acc6, %	Acc7, %	Acc8, %	Acc9, %	Acc10, %
Layer Norm	95.2	95.9	97.2	97.5	97.1	97.3	97.7	97.8	97.3	97.8
Batch Norm	96.2	97.2	97.6	97.9	97.9	98.0	98.0	97.9	98.2	98.2
Without Norm	79.2	92.0	94.9	95.9	96.6	96.6	97.2	97.3	97.2	97.1

Ниже приведены графики accuracy и cross entropy loss, полученные на этих трёх моделях на MNIST. Далее мы взяли Fashion MNIST и попытались сделать максимальное качество модели. На Fashion MNIST были выбраны другие гиперпараметры для повышения accuracy, кроме того авторы не делали экспериментов на этом датасете, ниже приведены графики.




Рис. 1: Cross Entropy Loss на MNIST




Рис. 2: Метрика Accuracy на MNIST




Рис. 3: Cross Entropy Loss на Fashion-MNIST




Рис. 4: Метрика Accuracy на Fashion-MNIST

### Выводы

В результате работы получилось повторить опыты оригинальной статьи [1] с дополнительной Layer нормализацией и было выяснено, что и Batch и Layer нормализации примерно одинаково быстро сходятся, в отличие от модели без нормализации. Опыты показывают, что Layer похож по качеству accuracy Batch нормализации, обе нормализации улучшают качество.

### Список литературы

- [1] Ioffe S., Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift //International conference on machine learning. – pmlr, 2015. – С. 448-456.
- [2] Ba J. L., Kiros J. R., Hinton G. E. Layer normalization //arXiv preprint arXiv:1607.06450. – 2016.